Devoir 3

IFT714 : Traitement automatique des langues naturelles

Enseignant : Amine Trabelsi

Étudiant : Mamadou Senghor

CIP : senm1912

Université de Sherbrooke

Département d'informatique

Hiver 2026

Date de remise : 18 février 2026

Table des matières

1 Question 1 : Perceptron (classification binaire) 2
1.1 (a) Contraintes imposées par les données 2
1.2 (b) Trouver un (w, b) satisfaisant strictement les contraintes 2

2 Question 2 : Différentiation automatique (Backpropagation) 3
2.1 (a) Calcul de $\frac{df}{dt}$ par passe arrière 3
2.2 (b) Passes avant et arrière (régression logistique + moindres carrés + L2) . 4
2.3 (c) Passes avant et arrière pour le MLP à deux sorties 5

3 Question 3 : Régression Softmax (classification multiclasse) 7
3.1 (a) Perte d'entropie croisée Softmax 7
3.2 (b) Gradient de la perte par rapport à z 8
3.3 (c) Gradient par rapport aux poids 9
3.4 (d) Lien avec la régression logistique binaire 9

1 Question 1 : Perceptron (classification binaire)

On considère un perceptron binaire avec $x = (x_1, x_2)^T$, $y \in \{0, 1\}$, $w = (w_1, w_2)^T$ et un biais b. Le score (pré-activation) est :

$$z = w^T x + b = w_1 x_1 + w_2 x_2 + b, \qquad \hat{y} = \mathbb{1}\{z > 0\}.$$

Ainsi,

$$y = 1 \Rightarrow z > 0, \qquad y = 0 \Rightarrow z \leq 0.$$

1.1 (a) Contraintes imposées par les données

Les exemples fournis sont :

$$(0, 0) \to 1, \qquad (1, 1) \to 1, \qquad (1, 0) \to 0.$$

1) Exemple $(0, 0) \to 1$

$$z = w_1 \cdot 0 + w_2 \cdot 0 + b = b.$$

Comme $y = 1$, il faut $z > 0$, donc :

$$\boxed{b > 0.}$$

2) Exemple $(1, 1) \to 1$

$$z = w_1 \cdot 1 + w_2 \cdot 1 + b = w_1 + w_2 + b.$$

Comme $y = 1$, il faut $z > 0$, donc :

$$\boxed{w_1 + w_2 + b > 0.}$$

3) Exemple $(1, 0) \to 0$

$$z = w_1 \cdot 1 + w_2 \cdot 0 + b = w_1 + b.$$

Comme $y = 0$, il faut $z \leq 0$, donc :

$$\boxed{w_1 + b \leq 0.}$$

Réponse finale

$$\boxed{\begin{cases} b > 0, \\ w_1 + w_2 + b > 0, \\ w_1 + b \leq 0. \end{cases}}$$

1.2 (b) Trouver un (w, b) satisfaisant strictement les contraintes

On impose :

$$\boxed{\begin{cases} b > 0, \\ w_1 + w_2 + b > 0, \\ w_1 + b < 0. \end{cases}}$$

1) Choix de b On choisit $b = 1$, ce qui satisfait $b > 0$.

2) Choix de w_1 La contrainte $w_1 + b < 0$ donne :

$$w_1 + 1 < 0 \;\Rightarrow\; w_1 < -1.$$

On prend $w_1 = -2$, donc $w_1 + b = -1 < 0$.

3) Choix de w_2 La contrainte $w_1 + w_2 + b > 0$ donne :

$$-2 + w_2 + 1 > 0 \;\Rightarrow\; w_2 > 1.$$

On prend $w_2 = 2$, donc $w_1 + w_2 + b = 1 > 0$.

Vérification

$$\begin{aligned}(0,0):\;\; z &= b = 1 > 0 \Rightarrow \hat{y} = 1,\\ (1,1):\;\; z &= -2 + 2 + 1 = 1 > 0 \Rightarrow \hat{y} = 1,\\ (1,0):\;\; z &= -2 + 1 = -1 < 0 \Rightarrow \hat{y} = 0.\end{aligned}$$

Réponse finale

$$\boxed{w = (-2,\, 2)^T, \qquad b = 1.}$$

2 Question 2 : Différentiation automatique (Backpropagation)

2.1 (a) Calcul de $\dfrac{df}{dt}$ par passe arrière

On considère :

$$f(x,y) = x^2 + y^2, \qquad x(t) = t, \qquad y(t) = e^t.$$

D'après la règle de la chaîne (notation en barres) :

$$\frac{df}{dt} = \frac{\partial f}{\partial x}\frac{dx}{dt} + \frac{\partial f}{\partial y}\frac{dy}{dt} = \bar{x}\,\frac{dx}{dt} + \bar{y}\,\frac{dy}{dt}, \qquad \bar{u} = \frac{\partial f}{\partial u}.$$

Passe avant

$$x = t, \qquad y = e^t, \qquad f = x^2 + y^2.$$

Passe arrière On initialise :

$$\bar{f} = \frac{df}{df} = 1.$$

1) Dérivées locales de f

$$\begin{aligned}\frac{\partial f}{\partial x} = 2x \quad &\Longrightarrow \quad \bar{x} = \bar{f}\frac{\partial f}{\partial x} = 1 \cdot 2x = 2x,\\ \frac{\partial f}{\partial y} = 2y \quad &\Longrightarrow \quad \bar{y} = \bar{f}\frac{\partial f}{\partial y} = 1 \cdot 2y = 2y.\end{aligned}$$

2) Dérivées de $x(t)$ et $y(t)$

$$\frac{dx}{dt} = 1, \qquad \frac{dy}{dt} = e^t = y.$$

3) Combinaison (règle de la chaîne)

$$\frac{df}{dt} = \bar{x}\frac{dx}{dt} + \bar{y}\frac{dy}{dt} = (2x) \cdot 1 + (2y) \cdot y = 2x + 2y^2.$$

En remplaçant $x = t$ et $y = e^t$, on obtient :

$$\boxed{\frac{df}{dt} = 2t + 2e^{2t}.}$$

2.2 (b) Passes avant et arrière (régression logistique + moindres carrés + L2)

On considère un seul exemple (x, y) et le modèle :

$$z = wx + b, \qquad \hat{y} = \sigma(z),$$

avec la perte moindres carrés :

$$L = \frac{1}{2}(\hat{y} - y)^2,$$

la régularisation L_2 :

$$R = \frac{1}{2}w^2,$$

et la perte régularisée :

$$L_{\text{reg}} = L + \lambda R.$$

Passe avant

$$\boxed{\begin{aligned} z &= wx + b, \\ \hat{y} &= \sigma(z), \\ L &= \frac{1}{2}(\hat{y} - y)^2, \\ R &= \frac{1}{2}w^2, \\ L_{\text{reg}} &= L + \lambda R. \end{aligned}}$$

Passe arrière (notation en barres : $\bar{u} = \dfrac{\partial L_{\textbf{reg}}}{\partial u}$) On initialise :

$$\bar{L}_{\text{reg}} = \frac{\partial L_{\text{reg}}}{\partial L_{\text{reg}}} = 1.$$

1) Noeud $L_{\textbf{reg}} = L + \lambda R$

$$\bar{L} = \bar{L}_{\text{reg}}\frac{\partial L_{\text{reg}}}{\partial L} = 1 \cdot 1 = 1, \qquad \bar{R} = \bar{L}_{\text{reg}}\frac{\partial L_{\text{reg}}}{\partial R} = 1 \cdot \lambda = \lambda.$$

2) Noeud $L = \frac{1}{2}(\hat{y} - y)^2$

$$\frac{\partial L}{\partial \hat{y}} = (\hat{y} - y) \quad \Longrightarrow \quad \bar{\hat{y}} = \bar{L}\frac{\partial L}{\partial \hat{y}} = 1 \cdot (\hat{y} - y) = \hat{y} - y.$$

3) Noeud $\hat{y} = \sigma(z)$ On utilise $\sigma'(z) = \sigma(z)(1 - \sigma(z)) = \hat{y}(1 - \hat{y})$:

$$\frac{\partial \hat{y}}{\partial z} = \hat{y}(1 - \hat{y}) \quad \Longrightarrow \quad \bar{z} = \bar{\hat{y}}\frac{\partial \hat{y}}{\partial z} = (\hat{y} - y)\,\hat{y}(1 - \hat{y}).$$

Ainsi, par définition,

$$\bar{z} = \frac{\partial L_{\text{reg}}}{\partial z}.$$

4) Noeud $z = wx + b$

$$\frac{\partial z}{\partial w} = x, \qquad \frac{\partial z}{\partial b} = 1.$$

Donc (contribution via z) :

$$\bar{w}_{(z)} = \bar{z}\,x, \qquad \bar{b} = \bar{z}.$$

5) Noeud $R = \frac{1}{2}w^2$

$$\frac{\partial R}{\partial w} = w \quad \Longrightarrow \quad \bar{w}_{(R)} = \bar{R}\frac{\partial R}{\partial w} = \lambda w.$$

6) Accumulation au paramètre w **et gradients finaux** Le paramètre w reçoit des contributions de deux chemins (via z et via R), donc le gradient total est la somme :

$$\boxed{\frac{\partial L_{\text{reg}}}{\partial w} = \bar{w} = \bar{w}_{(z)} + \bar{w}_{(R)} = \bar{z}\,x + \lambda w}$$

et pour le biais :

$$\boxed{\frac{\partial L_{\text{reg}}}{\partial b} = \bar{b} = \bar{z}}$$

avec

$$\boxed{\bar{z} = (\hat{y} - y)\,\hat{y}(1 - \hat{y}).}$$

Remarque Le terme λw provient uniquement de la régularisation L2, tandis que $\bar{z}\,x$ correspond à la contribution de la perte de prédiction.

2.3 (c) Passes avant et arrière pour le MLP à deux sorties

On considère un réseau de neurones à une couche cachée composé de 2 entrées, 2 neurones cachés sigmoïdes et 2 sorties linéaires. Pour un exemple (x_1, x_2), le modèle est défini par :

$$\begin{aligned}
z_i &= \sum_{j=1}^{2} w_{ij}^{[1]} x_j + b_i^{[1]}, \quad i = 1, 2, \\
h_i &= \sigma(z_i), \quad i = 1, 2, \\
\hat{y}_k &= \sum_{i=1}^{2} w_{ki}^{[2]} h_i + b_k^{[2]}, \quad k = 1, 2, \\
L &= \frac{1}{2}\sum_{k=1}^{2} (\hat{y}_k - y_k)^2.
\end{aligned}$$

Passe avant La passe avant consiste à calculer successivement les activations de la couche cachée, puis les sorties du réseau et la perte :

$$\boxed{\begin{aligned} z_i &= \sum_{j=1}^{2} w_{ij}^{[1]} x_j + b_i^{[1]}, \\ h_i &= \sigma(z_i), \\ \hat{y}_k &= \sum_{i=1}^{2} w_{ki}^{[2]} h_i + b_k^{[2]}, \\ L &= \frac{1}{2} \sum_{k=1}^{2} (\hat{y}_k - y_k)^2. \end{aligned}}$$

Passe arrière On calcule les gradients de la perte par rapport à tous les paramètres en appliquant la règle de la chaîne. On utilise la notation $\bar{u} = \dfrac{\partial L}{\partial u}$.

1) Dérivées par rapport aux sorties On dérive la perte :

$$\frac{\partial L}{\partial \hat{y}_k} = \frac{\partial}{\partial \hat{y}_k} \left(\frac{1}{2} \sum_{r=1}^{2} (\hat{y}_r - y_r)^2 \right) = \hat{y}_k - y_k.$$

Donc :

$$\boxed{\bar{\hat{y}}_k = \hat{y}_k - y_k.}$$

2) Couche de sortie (linéaire) Les sorties étant linéaires :

$$\frac{\partial \hat{y}_k}{\partial w_{ki}^{[2]}} = h_i, \qquad \frac{\partial \hat{y}_k}{\partial b_k^{[2]}} = 1.$$

Ainsi :

$$\boxed{\bar{w}_{ki}^{[2]} = \bar{\hat{y}}_k \, h_i, \qquad \bar{b}_k^{[2]} = \bar{\hat{y}}_k.}$$

3) Rétropropagation vers la couche cachée Chaque activation cachée h_i influence les deux sorties. Par accumulation des contributions :

$$\frac{\partial L}{\partial h_i} = \sum_{k=1}^{2} \frac{\partial L}{\partial \hat{y}_k} \frac{\partial \hat{y}_k}{\partial h_i} = \sum_{k=1}^{2} \bar{\hat{y}}_k \, w_{ki}^{[2]}.$$

Donc :

$$\boxed{\bar{h}_i = \sum_{k=1}^{2} \bar{\hat{y}}_k \, w_{ki}^{[2]}.}$$

4) Rétropropagation à travers la sigmoïde On a $h_i = \sigma(z_i)$ et :

$$\sigma'(z_i) = \sigma(z_i)(1 - \sigma(z_i)) = h_i(1 - h_i).$$

Par la règle de la chaîne :

$$\boxed{\bar{z}_i = \frac{\partial L}{\partial z_i} = \bar{h}_i \, h_i(1 - h_i).}$$

5) Couche d'entrée : gradients des paramètres Comme

$$z_i = \sum_{j=1}^{2} w_{ij}^{[1]} x_j + b_i^{[1]},$$

on obtient :

$$\frac{\partial z_i}{\partial w_{ij}^{[1]}} = x_j, \qquad \frac{\partial z_i}{\partial b_i^{[1]}} = 1.$$

Ainsi :

$$\boxed{\bar{w}_{ij}^{[1]} = \bar{z}_i\, x_j, \qquad \bar{b}_i^{[1]} = \bar{z}_i.}$$

Résumé des gradients finaux

$$\boxed{\begin{aligned} \bar{\hat{y}}_k &= \hat{y}_k - y_k, \\ \bar{w}_{ki}^{[2]} &= \bar{\hat{y}}_k\, h_i, \qquad \bar{b}_k^{[2]} = \bar{\hat{y}}_k, \\ \bar{h}_i &= \sum_{k=1}^{2} \bar{\hat{y}}_k\, w_{ki}^{[2]}, \\ \bar{z}_i &= \bar{h}_i\, h_i(1 - h_i), \\ \bar{w}_{ij}^{[1]} &= \bar{z}_i\, x_j, \qquad \bar{b}_i^{[1]} = \bar{z}_i. \end{aligned}}$$

3 Question 3 : Régression Softmax (classification multiclasse)

On considère un problème de classification multiclasse avec K classes. Pour une entrée $x \in \mathbb{R}^d$, le modèle Softmax est défini par :

$$z_k = w_k^T x + b_k, \qquad k = 1, \ldots, K,$$

$$\hat{y}_k = \frac{e^{z_k}}{\sum_{l=1}^{K} e^{z_l}},$$

où $\hat{y}_k = p(y = k \mid x)$.

La cible est encodée en **one-hot** :

$$y = (y_1, \ldots, y_K)^T, \qquad y_k = \mathbb{1}\{y = k\}.$$

3.1 (a) Perte d'entropie croisée Softmax

La vraisemblance pour un exemple (x, y) s'écrit :

$$p(y \mid x) = \prod_{k=1}^{K} \hat{y}_k^{y_k}.$$

La perte d'entropie croisée est définie comme la log-vraisemblance négative :

$$L_{\mathrm{SCE}}(y, \hat{y}) = -\log p(y \mid x).$$

En substituant l'expression de la vraisemblance :

$$L_{\text{SCE}}(y, \hat{y}) = -\log\left(\prod_{k=1}^{K} \hat{y}_k^{y_k}\right).$$

En utilisant les identités $\log \prod a_k = \sum \log a_k$ et $\log(a^b) = b \log a$:

$$L_{\text{SCE}}(y, \hat{y}) = -\sum_{k=1}^{K} y_k \log(\hat{y}_k).$$

$$\boxed{L_{\text{SCE}}(y, \hat{y}) = -\sum_{k=1}^{K} y_k \log(\hat{y}_k)}$$

3.2 (b) Gradient de la perte par rapport à z

On cherche le gradient $\nabla_z L_{\text{SCE}}$.
On part de :

$$L_{\text{SCE}} = -\sum_{k=1}^{K} y_k \log(\hat{y}_k), \qquad \hat{y}_k = \frac{e^{z_k}}{\sum_{l=1}^{K} e^{z_l}}.$$

Par la règle de la chaîne, pour $l \in \{1, \ldots, K\}$:

$$\frac{\partial L_{\text{SCE}}}{\partial z_l} = -\sum_{k=1}^{K} y_k \frac{1}{\hat{y}_k} \frac{\partial \hat{y}_k}{\partial z_l}.$$

La dérivée du Softmax est donnée par :

$$\frac{\partial \hat{y}_k}{\partial z_l} = \hat{y}_k(\delta_{kl} - \hat{y}_l),$$

où δ_{kl} est le symbole de Kronecker.
En substituant :

$$\frac{\partial L_{\text{SCE}}}{\partial z_l} = -\sum_{k=1}^{K} y_k(\delta_{kl} - \hat{y}_l).$$

On sépare les termes :

$$\frac{\partial L_{\text{SCE}}}{\partial z_l} = -\sum_{k=1}^{K} y_k \delta_{kl} + \sum_{k=1}^{K} y_k \hat{y}_l.$$

Comme y est one-hot, on a $\sum_{k=1}^{K} y_k = 1$, donc :

$$\frac{\partial L_{\text{SCE}}}{\partial z_l} = -y_l + \hat{y}_l.$$

Ainsi :

$$\boxed{\nabla_z L_{\text{SCE}}(y, \hat{y}) = \hat{y} - y}$$

3.3 (c) Gradient par rapport aux poids

On considère un ensemble d'entraînement :

$$D = \{(x^{(i)}, y^{(i)})\}_{i=1}^{m},$$

et la perte totale :

$$L_{\text{SCE}}^{D} = \sum_{i=1}^{m} L_{\text{SCE}}^{(i)}.$$

Pour un exemple i, on a :

$$z_l^{(i)} = \sum_{j=1}^{d} w_{lj} x_j^{(i)} + b_l.$$

Par la règle de la chaîne :

$$\frac{\partial L_{\text{SCE}}^{(i)}}{\partial w_{lj}} = \frac{\partial L_{\text{SCE}}^{(i)}}{\partial z_l^{(i)}} \frac{\partial z_l^{(i)}}{\partial w_{lj}}.$$

Or :

$$\frac{\partial z_l^{(i)}}{\partial w_{lj}} = x_j^{(i)}, \qquad \frac{\partial L_{\text{SCE}}^{(i)}}{\partial z_l^{(i)}} = \hat{y}_l^{(i)} - y_l^{(i)}.$$

Ainsi :

$$\frac{\partial L_{\text{SCE}}^{(i)}}{\partial w_{lj}} = (\hat{y}_l^{(i)} - y_l^{(i)}) x_j^{(i)}.$$

En sommant sur l'ensemble des données :

$$\boxed{\frac{\partial L_{\text{SCE}}}{\partial w_{lj}} = \sum_{i=1}^{m} (\hat{y}_l^{(i)} - y_l^{(i)}) x_j^{(i)}}$$

3.4 (d) Lien avec la régression logistique binaire

En régression logistique binaire, le gradient s'écrit :

$$\frac{\partial L}{\partial w_j} = \sum_{i=1}^{m} (\hat{y}^{(i)} - y^{(i)}) x_j^{(i)}.$$

La régression Softmax généralise directement ce résultat au cas multiclasse : chaque classe l possède son propre vecteur de poids w_l, et le terme $(\hat{y}_l - y_l)$ joue le même rôle que l'erreur en classification binaire.

La régression Softmax est l'extension de la régression logistique au cas multiclasse, combinée à la perte d'entropie croisée.